

tdgaCNN における適応度評価 手法の検討

創発ソフトウェア研究室
B3 平 智隆

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

はじめに


- 近年，機械学習を用いた画像識別に注目
- 畳み込みニューラルネットワークによる画像識別
(Convolutional Neural Network: CNN)
- 問題の高度化により，CNN の構造が複雑化
→ 人手で最適化することは難しい

はじめに

□ gaCNN

- CNN の構造の最適化に遺伝的アルゴリズム (Genetic Algorithm: GA) を利用

- GA の選択ルールを検討が不十分




多様性を考慮した選択ルールを採用した tdgaCNN

はじめに

- tdgaCNN の探索フェーズ

- 適応度の計算方法 → 従来: 1 エポック



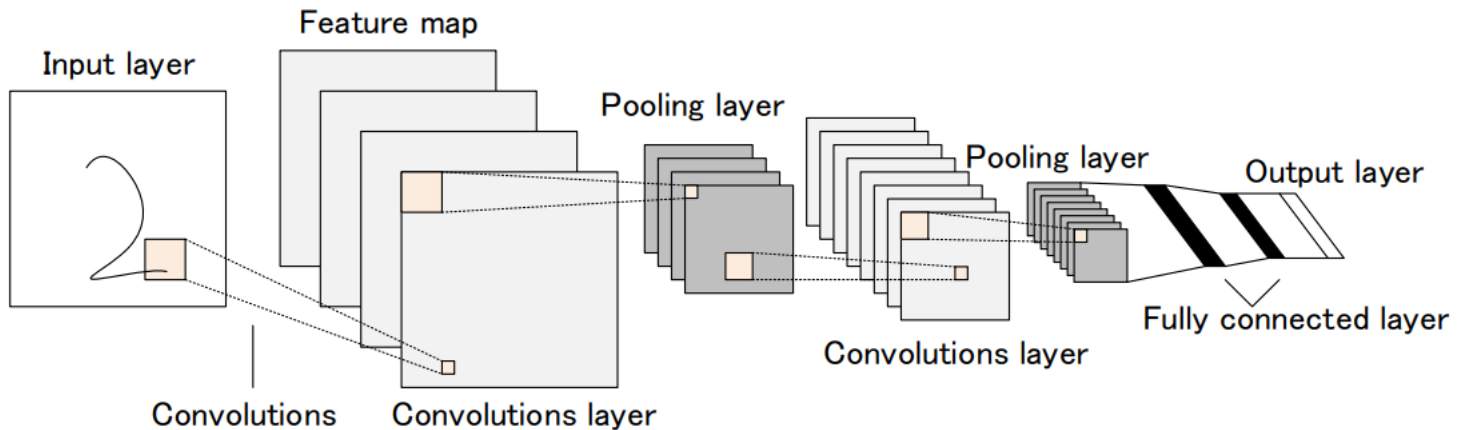
より良い個体が得られる適応度の評価方法を検討

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

畳み込みニューラルネットワーク

- 畳み込みニューラルネットワーク
(Convolutional Neural Network: CNN)
- 画像認識分野で広く利用



野村 泰稔, 村尾 彩希, 阪口 幸広, 古田 均. 深層畳み込みニューラルネットワークに基づくコンクリート表面のひび割れ検出システム. 土木学会論文集F6 (安全問題), 2017, 73 巻, 2 号


遺伝的アルゴリズム

遺伝的アルゴリズム (Genetic Algorithm: GA)

- 生物の進化からヒントを得た最適化手法
- 解の遺伝子を表現する配列に交叉，突然変異，選択といった操作を繰り返し適用
- 各個体について適応度を計算し，高いものを次世代に残し，低いものを淘汰

gaCNN

- CNN の構造を遺伝子符号化
- GA による探索でより良い CNN 構造を獲得



FashionMNIST, MNIST で競合 16 手法のうち
12 手法の精度を凌駕

熱力学的遺伝アルゴリズム

□ 熱力学的遺伝アルゴリズム

(Thermodynamical Genetic Algorithm: TDGA)

□ GA に熱力学的選択ルールを適用

□ 個体の多様性を維持することがねらい

→ 初期収束問題の解消

可変長遺伝子型熱力学的選択ルール

□ 自由エネルギー

$$F = \langle E \rangle - HT$$

エネルギー最小化
を追求する項

系の多様性維持を
追求する項

F : 自由エネルギー

$\langle E \rangle$: システムの平均エネルギー

H : エントロピー

T : 温度

多様性を維持しつつエネルギー最小化を追求できる

可変長遺伝子型熱力学的選択ルール

□ エントロピー

$$H = H_D, \quad H_D = \frac{\sum_{s \in S \setminus p} L(p, s)}{|S|}$$

p : 新たに選択する個体

S : 選択済みの個体集合に p を加えた集合

$|S|$: S の要素数

$L(x, y)$: 個体 x と個体 y における遺伝子配列の層
に対する Levenshtein 距離

可変長遺伝子型熱力学的選択ルール

□ エントロピー

$$H = H_D, \quad H_D = \frac{\sum_{s \in S \setminus p} L(p, s)}{|S|}$$

□ H_D の値が大きいほど個体に多様性がある

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

提案手法

□提案手法: tdgaCNN

□CNN アーキテクチャの探索に TDGA を利用

tdgaCNN の流れ

1. 初期母集団を生成
2. 母集団の個体の適応度を評価
3. 選択, 交叉, 突然変異による次世代の母集団の生成
4. 2 ~ 3 を世代回数だけ反復
5. 最終世代で最も適応度が高い個体を本学習

tdgaCNN — 遺伝子符号化

□ 遺伝子 → 層と活性化関数の組

□ 層の候補:

畳み込み層, プーリング層, 全結合層

□ 活性化関数の候補:

ReLU, tanh, Sigmoid

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

本実験の概要

□ 先行研究

□ 適応度評価のために 1 エポックのみ学習

□ 本実験

$$\sum_i n_i g_i = c$$

n_i : i 番目のエポック数

g_i : エポック数が n_i である世代の数

c : 定数


□ 計算量が一定になるように設定

□ 今回は $c = 80$ として実験

初期個体群の作成

- 1 度の実験にかかる時間を短縮する目的
- ランダムな 100 個体を 20 世代探索

ランダムな
初期個体群

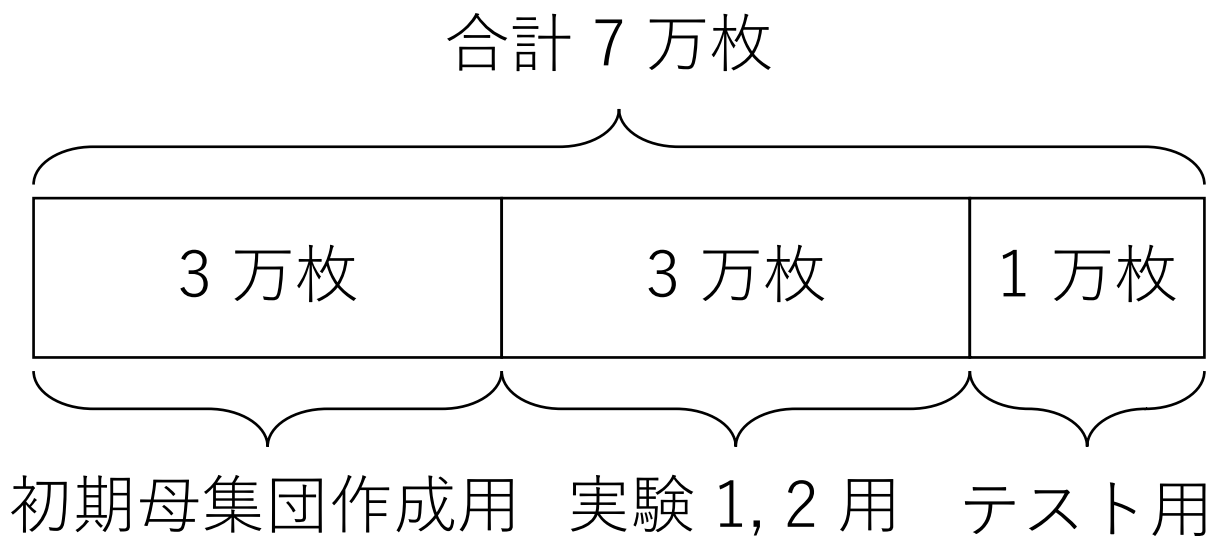


tdgaCNN 20 世代

実験用の
初期個体群

データセット

■使用データセット: FashionMNIST



実験 1

□ 探索フェーズでのエポック数を固定


世代数	エポック数
80	1
40	2
20	4
16	5
10	8
8	10

□ 6 パターンで実験

実験 2

□ エポック数を変化させながら探索

世代数	エポック数
16	1
8	2
4	4
2	8
1	16



□ エポック数増加と減少の 2 パターンで実験

実験 1, 2 実験条件



個体数	100
層数	10
最小全結合層数	1
最大全結合層数	3
選択 : 交叉 : 突然変異	4 : 4 : 2
本学習エポック数	100
探索バッチサイズ	24
本学習バッチサイズ	16
学習率	1e-4
最適化手法	Adam
温度	0.04

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- **実験結果**
- まとめと今後の課題

初期個体群の作成

■ ランダムな個体 100 体を初期個体とし
1 エポック 20 世代探索



平均適応度: 63.26 % → 85.64 %

実験 1 —— 最終的な識別精度


■ 本学習後の最良個体をテストしたときの
最良識別精度

	識別精度 [%]		識別精度 [%]
80 世代 1 エポック	92.04	16 世代 1 エポック	93.09
40 世代 2 エポック	92.13	10 世代 2 エポック	90.00
20 世代 4 エポック	92.26	8 世代 10 エポック	92.29

■ 16 世代 1 エポックでピークを迎える

実験 1 —— 考察

エポック数を適切に設定し学習



将来的な性能の予測が容易


実験 2 — 最終的な識別精度

- 本学習後の最良個体をテストしたときの最良識別精度


	1 回目 [%]	2 回目 [%]	平均 [%]
エポック数 増加	91.91	92.39	92.15
エポック数 減少	91.34	91.96	91.65

- 探索が進むにつれてエポック数を増やした方が
良い識別精度

実験 2 — 適応度の推移




エポック数を増加させた時



エポック数を減少させた時

実験 2 — 考察

探索終盤にエポック数増加



本学習で良い性能を発揮

■ 本学習は 100 エポック

→ 本学習直前に多いエポック数で評価すると
本学習でも良い性能を発揮

目次

- はじめに
- 要素技術
- 提案手法
- 実験概要
- 実験結果
- まとめと今後の課題

まとめ

- 本実験で確認できたこと
 - 1 エポックよりも，適応度評価に最適なエポック数がある
 - 探索終盤に適応度評価のための学習エポック数を増やす方が，より良い個体が得られる

今後の課題

- 試行回数を増やす
→ 適応度評価手法ごとの信頼区間を調査する
- 様々な条件下で実験するときの適応度評価
のための学習エポック数最適化手法を提案する

ご静聴ありがとうございました